BrewFlow Final Project - Ergebnisbericht

Von der PostgreSQL-Quelle zum automatisierten Data Warehouse und Power-BI-Bericht

Projektteile 1 bis 4 | Abschlussstand 7. Oktober 2026

5	**6**	**24**
Quelltabellen	Warehouse-Tabellen	Bestellungen
34	**177,00 €**	**3**
Fakten	Gesamtumsatz	Lakeflow-Tasks

1. Ziel und Projektumfang

Ziel des Projekts war der Aufbau einer vollständigen analytischen Datenstrecke für BrewFlow Coffee Co.: operative Quelldaten in PostgreSQL, ein dimensionales Warehouse, reproduzierbare ETL-Skripte, eine automatisierte Databricks-Pipeline und ein Power-BI-Bericht. Im Mittelpunkt stehen nachvollziehbare Datenherkunft, historisierte Kundenmerkmale und überprüfbare End-to-End-Ergebnisse.

2. Teil 1 - OLTP-Quelle in PostgreSQL

Im Schema brewflow_oltp wurden fünf operative Tabellen erstellt: customers, stores, products, orders und order_items. Der ursprüngliche Beispieldatensatz umfasst 10 Kunden, 5 Filialen, 8 Produkte, 22 Bestellungen und 32 Bestellpositionen. Die Bestellsummen wurden gegen die Summe ihrer Positionen geprüft.

Tabelle	Rolle
customers	Kundenstammdaten und loyalty_tier
stores	Filialstammdaten
products	Produktstammdaten
orders	Bestellkopf mit Kunde, Filiale, Datum und Kanal
order_items	Bestellpositionen mit Menge und Einzelpreis

3. Teil 2 - Dimensionales Warehouse

Das Warehouse folgt einem Star-Schema. Die Faktentabelle fact_order_items hat die Granularität "eine Zeile pro Bestellposition". Sie ist mit fünf Dimensionen verbunden.

Warehouse-Tabelle	Modellierung
dim_customer	SCD Type 2 für loyalty_tier
dim_product	SCD Type 1
dim_store	SCD Type 1
dim_channel	Referenzdimension für in-store / mobile-app
dim_date	Kalenderdimension 2020-2030
fact_order_items	Bestellpositionen, quantity, unit_price, revenue

Die Kundendimension verwendet customer_sk als Surrogatschlüssel. effective_from, effective_to und is_current steuern die Historisierung. revenue wird aus quantity × unit_price abgeleitet.

4. Teil 3 - ETL von OLTP über Staging ins Warehouse

Die ETL-Strecke wurde in klar getrennte Schritte zerlegt: Quelle vollständig ins Staging kopieren, Dimensionen laden und anschließend die Faktentabelle ergänzen. Die drei Skripte sind klar benannt und getrennt ausführbar.

Skript	Aufgabe
03_copy_to_staging.sql	Vollständige Kopie der fünf OLTP-Tabellen ins Staging
04_load_dimensions.sql	SCD2-Kunden, Type-1-Dimensionen, Kanal- und Kalenderdimension
05_load_facts.sql	Bestellpositionen mit temporaler Kundenzuordnung in fact_order_items

Idempotenz
Der Fact-Load nutzt order_item_id als Match-Key und fügt nur noch nicht vorhandene Positionen ein. Wiederholte Läufe erzeugen deshalb keine Duplikate.

5. Teil 4 - Databricks und Lakeflow-Automatisierung

In Databricks wurden die drei Schemata brewflow_oltp, brewflow_staging und brewflow_warehouse angelegt. Der Lakeflow-Job brewflow_nightly_pipeline besteht aus drei voneinander abhängigen SQL-Tasks.

Task	Abhängigkeit
copy_to_staging	Starttask
load_dimensions	nach copy_to_staging
load_facts	nach load_dimensions

Der aktive Zeitplan ist täglich um 02:00 Uhr (Europe/Berlin). Ein automatisch durch den Scheduler gestarteter Lauf am 7. Oktober 2026 um 02:00 Uhr wurde erfolgreich abgeschlossen.

6. SCD Type 2 und historisch korrekte Zuordnung

Zur Prüfung von SCD Type 2 wurde Sofias loyalty_tier von Bronze auf Silver geändert. Die historische Bronze-Version wurde geschlossen und als nicht aktuell markiert; die Silver-Version wurde als neue aktuelle Version angelegt.

Version	loyalty_tier	Gültigkeit	is_current
Historisch	Bronze	bis 04.10.2026	FALSE
Aktuell	Silver	ab 05.10.2026	TRUE

Zusätzlich wurde eine verspätet eintreffende Bestellung vom 03.01.2024 angelegt. Der temporale Join ordnete sie korrekt der historischen Bronze-Version zu. Damit ist die Point-in-Time-Logik nachgewiesen.

7. End-to-End-Validierung

Der ursprüngliche Bestand und der Endstand nach den Änderungsszenarien wurden getrennt geprüft. Dadurch bleiben die ursprünglich geforderten 32 Fakten nachvollziehbar, während der aktuelle Endstand korrekt 34 Fakten umfasst.

Kennzahl	Ursprünglicher Bestand	Endstand nach Tests
Kunden aktuell	10	11
Kundenversionen	10	12
Bestellungen	22	24

Bestellpositionen / Fakten	32	34
Fehlende Positionen	0	0
Gesamtumsatz	169,00 €	177,00 €

8. Power BI

Power BI ist mit dem Warehouse verbunden. Der Bericht verwendet die sechs Warehouse-Tabellen und zeigt Kennzahlen sowie Auswertungen nach Produktkategorie, Filiale, Stadt, Kanal und Zeit. Die Datenprüfungsseite enthält zusätzlich den historischen Einzelnachweis für die verspätete Bestellung.

Auswertung	Bestätigter Wert
Gesamtumsatz	177,00 €
Bestellungen	24
Bestellpositionen	34
Umsatz in-store	97,60 € / 20 Positionen
Umsatz mobile-app	79,40 € / 14 Positionen
Höchste Produktkategorie	Coffee: 59,70 €
Höchste Filiale	BrewFlow Westside: 51,30 €

9. Datenqualität und Sicherheitsprüfung

Die Quelle, Staging- und Warehouse-Ergebnisse wurden mit Zeilenanzahlen, Eindeutigkeits- und Vollständigkeitsprüfungen kontrolliert. Für die geprüften SQL- und YAML-Dateien wurden keine offensichtlichen Passwörter, persönlichen Tokens, Secrets, JDBC-Verbindungsstrings oder eingebetteten URLs gefunden. Technische Databricks-IDs in der Jobdefinition sind Konfigurations-IDs und keine Zugangsdaten.

10. Ergebnis und nächste Verbesserung

Das Projekt erfüllt die geforderte End-to-End-Strecke von der Quelle bis zum BI-Bericht. SCD Type 2, ein verspätet eintreffender Fakt, wiederholbare ETL-Läufe und ein geplanter Nachtjob wurden nachgewiesen. Der aktuelle Endstand ist konsistent: 24 Bestellungen, 34 eindeutige Fakten, 0 fehlende Positionen und 177,00 € Umsatz.

Empfohlene Weiterentwicklung

Als nächste technische Verbesserung sollte der Fact-Load neben neuen Positionen auch nachträgliche Korrekturen bereits geladener Positionen kontrolliert verarbeiten und die Validierungsergebnisse dauerhaft protokollieren.

Abgabe-Check

✓ 5 OLTP-Quelltabellen erstellt und befüllt
✓ Quellvalidierungen vorhanden
✓ 6 Warehouse-Tabellen erstellt
✓ SCD-Type-2-Spalten in dim_customer vorhanden
✓ ETL-Skripte gespeichert und klar benannt
✓ Fact-Load validiert: 32 ursprüngliche, 34 finale Fakten
✓ Databricks-Schemata OLTP, Staging und Warehouse vorhanden
✓ Lakeflow-Job mit 3 Tasks und 02:00-Uhr-Zeitplan nachgewiesen
✓ SCD-Simulation und historischer Nachweis vorhanden
✓ Power BI mit Warehouse verbunden
✓ Ergebnisbericht und aktualisierte Zusammenfassung als PDF erstellt
✓ SQL-/YAML-Dateien ohne offensichtliche Zugangsdaten/Secrets